Tech Challenge – IA Aplicada à Saúde – Fase 4

Monitoramento Multimodal: Análise de Voz e Vídeo, Detecção de Anomalias e Alertas com IA em Nuvem

Marcelo Viana de Araujo – RM372707
Nirton Afonso de Oliveira Filho – RM370221
Valkiria Nonato de Faria – RM373256
Benicio Antonio Cardoso – RM371527

Pós-Graduação em IA para Devs

2026

Repositório GitHub da Fase 4:
https://github.com/Val-Faria/TechChallengeFase4/tree/Nirton

Dataset de vídeo – Uterus v4:
https://universe.roboflow.com/machinelearning-yekk6/uterus-qn1he/dataset/4

Sumário

1 Resumo **3**

2 Introdução e objetivos **3**

3 Arquitetura da solução **3**

4 Dados e protocolo experimental **4**
4.1 Áudio e separação por frases 4
4.2 Vídeo e reserva de origem 5
4.3 Séries e dados textuais 5

5 Análise de áudio **5**
5.1 Características e classificador 5
5.2 Transcrição e gravações externas 7
5.3 Alterações vocais observacionais 7

6 Análise de vídeo **7**
6.1 Detector e regra temporal 7
6.2 Anotações, calibração e compatibilidade visual 9
6.3 Resultados históricos da equipe 11

7 Análise textual em nuvem **11**

8 Anomalias e monitoramento temporal **12**
8.1 Sinais vitais e movimentação 12
8.2 Prescrições 13
8.3 Inferência em mídias e latência 13

9 Fusão, entrega e revisão **14**

10 Verificação e reprodução **15**
10.1 Notebooks e ambiente 16

11 Limitações e conclusão **16**

12 Referências **18**

A Manifesto de evidências **19**

1 Resumo

Este trabalho apresenta um protótipo de monitoramento multimodal voltado à saúde da mulher. A solução combina análise de voz, detecção de objetos em vídeo, interpretação textual em nuvem e acompanhamento de sinais vitais, prescrições e movimentação. As saídas convergem para um contrato comum que conserva a origem, a prioridade e a disponibilidade de cada modalidade. Os sinais são registrados em uma caixa local de revisão, com relatórios automáticos e confirmação de leitura.

O módulo de áudio utiliza Whisper, Librosa e Random Forest sobre um corpus sintético de 1.180 gravações. O módulo de vídeo emprega YOLOv8s e uma regra temporal de visualização da área crítica. A análise textual utiliza a API da OpenAI, conforme a alternativa de fornecedor autorizada pelo professor. O monitoramento estruturado utiliza referências anteriores e estatística robusta. Os resultados demonstram a execução do fluxo e identificam limitações de generalização: as fontes não são pareadas por paciente, o áudio é sintético e a referência temporal do vídeo depende de anotações cuja exaustividade não foi confirmada.

Palavras-chave: análise multimodal; voz; visão computacional; anomalias; monitoramento; revisão humana.

2 Introdução e objetivos

O Tech Challenge da Fase 4 propõe analisar dados médicos multimodais para identificar alterações e encaminhá-las à equipe responsável. O projeto reúne processamento de áudio e vídeo, análise textual gerenciada, detecção de anomalias e entrega de alertas. O recorte adotado pela equipe combina laparoscopia ginecológica e análise observacional da voz.

São objetivos do trabalho: processar as modalidades por componentes reutilizáveis; identificar eventos e alterações temporais; integrar a análise textual em nuvem; preservar a rastreabilidade dos resultados; e demonstrar o percurso entre a observação, o alerta e sua revisão. O sistema é um protótipo acadêmico e não altera tratamentos ou condutas.

3 Arquitetura da solução

Áudio e vídeo são mantidos em módulos separados; contratos, detectores, persistência e painel pertencem ao pacote `src/techchallenge4`. Os notebooks utilizam esse código, sem duplicar as regras de decisão. Os scripts permitem reproduzir extração, avaliação e geração de relatórios.

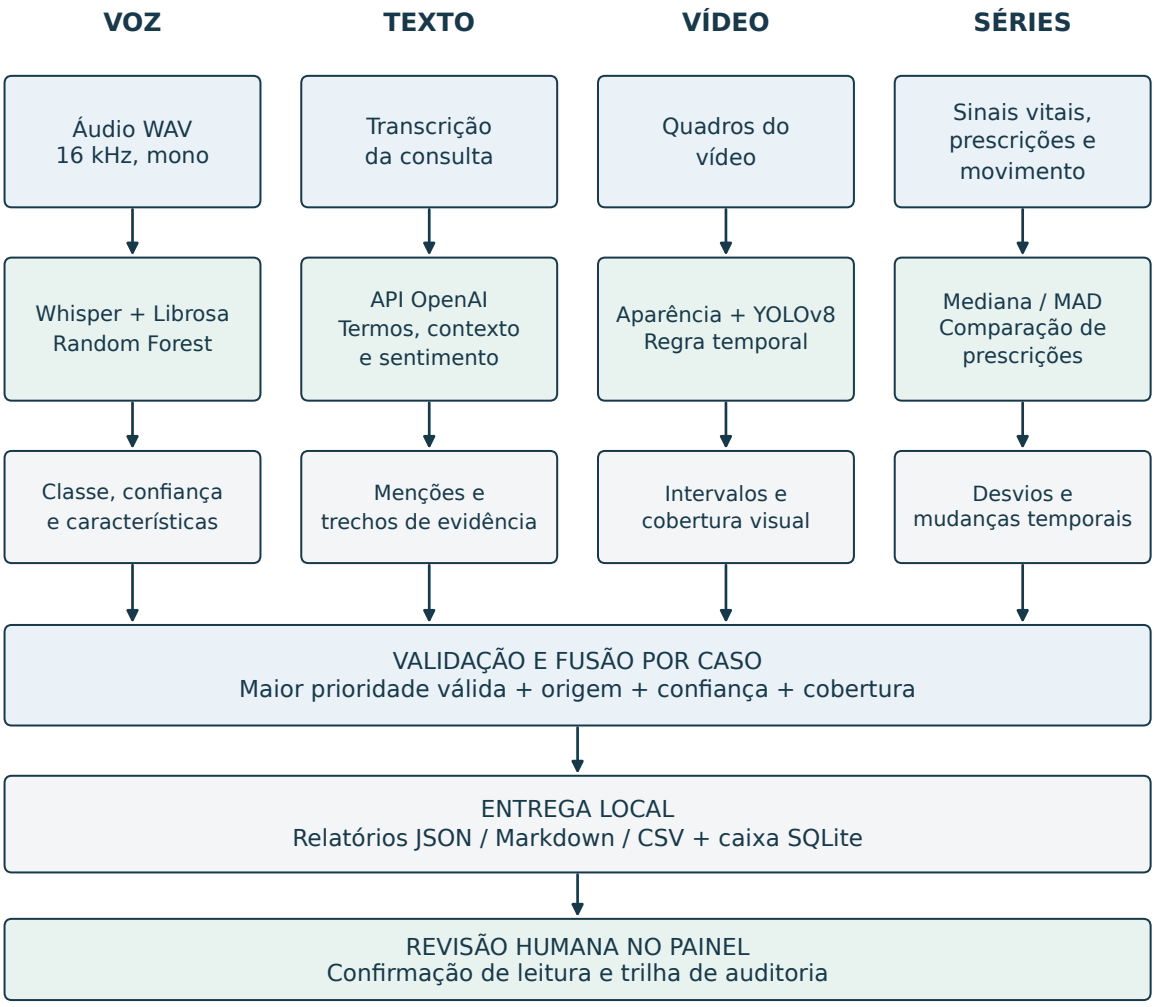


Figura 1: Fluxo multimodal: cada modalidade produz evidências que convergem para a fusão e a caixa de revisão. A transcrição da voz alimenta a análise textual; as fontes do experimento são associadas por caso e não representam um paciente pareado.

A fusão conserva a maior prioridade entre os sinais válidos. Uma modalidade neutra não cancela um alerta de maior gravidade. Fonte ausente, baixa confiança e cobertura parcial continuam identificadas e solicitam revisão. A associação das modalidades é didática, sem sincronização de um paciente real.

4 Dados e protocolo experimental

4.1 Áudio e separação por frases

O corpus contém 1.180 WAVs: 380 de ansiedade/hesitação, 400 neutros e 400 de tristeza. São 295 gravações originais, cada uma com quatro versões: original, lenta, rápida e com ruído. As falas foram produzidas por síntese de voz; seus rótulos representam as condições de construção do experimento.

A unidade de separação é a família de frase-base. Gravações e aumentos de uma mesma família permanecem no mesmo conjunto: 712 exemplos de treino, 172 de validação, 176 de teste e 120 de reserva. Não há sobreposição de famílias, gravações originais ou hashes entre partições. O modelo avaliado foi ajustado somente no treino; o classificador anterior da equipe, treinado em todo o corpus, é histórico e não participa dessas métricas.

Além do corpus, foram produzidas seis falas com textos novos e duas vozes diferentes da voz de origem. Elas não integram o ajuste nem possuem rótulos clínicos independentes. Outras seis sínteses, distintas das anteriores, fornecem referências e controles físicos para a análise de pausas.

4.2 Vídeo e reserva de origem

A fonte é o Uterus Dataset v4, do Roboflow Universe. A página anuncia 1.368 imagens; o ZIP contém 1.367: 1.196 de treino, 114 de validação e 57 de teste. A preparação verifica CRC, integridade e duplicatas. As anotações misturam polígonos e caixas; 418 polígonos utilizados foram convertidos em caixas envolventes, sem criar rótulos anatômicos adicionais.

O prefixo `UterusClip_mov` fornece 776 imagens de treino, 74 de validação e 37 de teste. O prefixo `2024-09-26-20-27-33_mp4` foi excluído do desenvolvimento: suas 420 versões aumentadas não são utilizadas, e 60 imagens originais formam a reserva. A identidade de clipe inferida do nome não comprova independência por paciente. As montagens repetem cada imagem por dois segundos; seus intervalos não representam a duração original de eventos cirúrgicos.

Uma fonte complementar do TVASurg, Universidade de Toronto, foi utilizada somente para verificação qualitativa. Trata-se de um vídeo didático editado, sem referência independente de eventos clínicos. As imagens não integram o repositório ou este relatório.

4.3 Séries e dados textuais

Sinais vitais, prescrições e movimentação são séries sintéticas com timestamps. Elas permitem verificar ordenação, cálculo de desvios, fusão e entrega incremental. Os textos de consulta são transcrições de falas sintéticas e casos de controle com afirmação, negação e contexto histórico. As fontes disponíveis não constituem uma coorte clínica.

5 Análise de áudio

5.1 Características e classificador

Os WAVs são convertidos para mono a 16 kHz. O Whisper tiny transcreve em português; o Librosa calcula as características utilizadas pelo Random Forest.

Característica	Cálculo
Duração	Quantidade de amostras dividida pela taxa de amostragem.
Energia média	Média da energia RMS em janelas.
Proporção de pausas	Fração fora dos intervalos sonoros, com `top_db=30`.
Ritmo	Palavras reconhecidas por minuto de gravação.
Tom médio e variação	Média e desvio padrão dos valores válidos de F0 por pYIN.

O Random Forest usa 200 árvores, semente 42 e ponderação balanceada de classes. Não houve busca de hiperparâmetros ou reajuste com as reservas. Na integração, confiança inferior a 0,70 permanece inconclusiva. As classes de prosódia não são diagnósticos e não demonstram, por si, detecção de fadiga, disartria ou dificuldade respiratória.

A avaliação foi regenerada com partições isoladas por família de frase-base. Os valores abaixo são extraídos de `evidence/audio_reproducao.json`; cada partição é reportada separadamente.

Partição	Exemplos	Acurácia	F1 macro
Validação	172	93,60%	0,933
Teste	176	86,36%	0,862
Verificação cega	120	88,33%	0,883

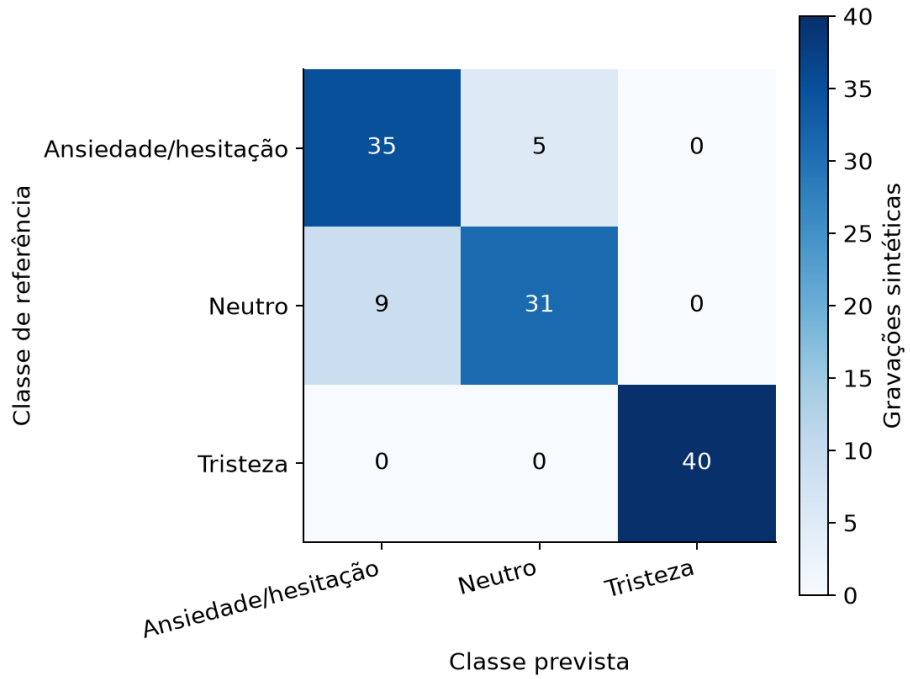


Figura 2: Matriz de confusão da reserva de frases do classificador emocional sintético.

5.2 Transcrição e gravações externas

O Whisper apresentou 13 erros em 109 palavras nas seis gravações externas, WER agregado de 11,9%. No caso novo-03, a expressão "falta de ar" foi transcrita como "falta de área". A API `gpt-4o-mini-transcribe` apresentou zero erros nessa pequena amostra, com os mesmos hashes de WAV e normalização textual. A comparação não estabelece superioridade geral nem desempenho em pacientes.

Todas as seis previsões acústicas externas ficaram abaixo de 0,70. Elas são encaminhadas como inconclusivas. O ritmo do classificador permanece baseado no Whisper para manter a representação do treinamento; a transcrição em nuvem alimenta a análise textual separadamente.

5.3 Alterações vocais observacionais

A comparação intra-voz utiliza duas gravações anteriores da mesma voz, com referência congelada antes da observação nova. Janelas RMS de 20 ms estimam atividade vocal. A regra exige aumento de pelo menos 0,20 na proporção de pausas e redução do trecho vocal mediano para até 65% da referência. Saturação, silêncio ou duração insuficiente tornam o resultado inconclusivo. Os limites são demonstrativos e não atribuem causa médica às alterações.

6 Análise de vídeo

6.1 Detector e regra temporal

O modelo avaliado é um YOLOv8s com ajuste a partir de pesos COCO, diferente do peso original da frente de vídeo. A inferência detecta instrumentos e útero em resolução de 416×416 pixels. O script exige confiança mínima de 0,4 para instrumento e 0,6 para útero. Instrumento detectado sem detecção sustentada de útero por pelo menos cinco segundos gera um sinal, com tolerância de um segundo para interrupções curtas.

A prioridade é baixa a partir de cinco segundos, média a partir de dez e alta a partir de quinze, ou com pelo menos três eventos. A ausência de detecção não comprova ausência anatômica. Os sinais solicitam revisão e podem ocorrer durante etapas normais do procedimento.

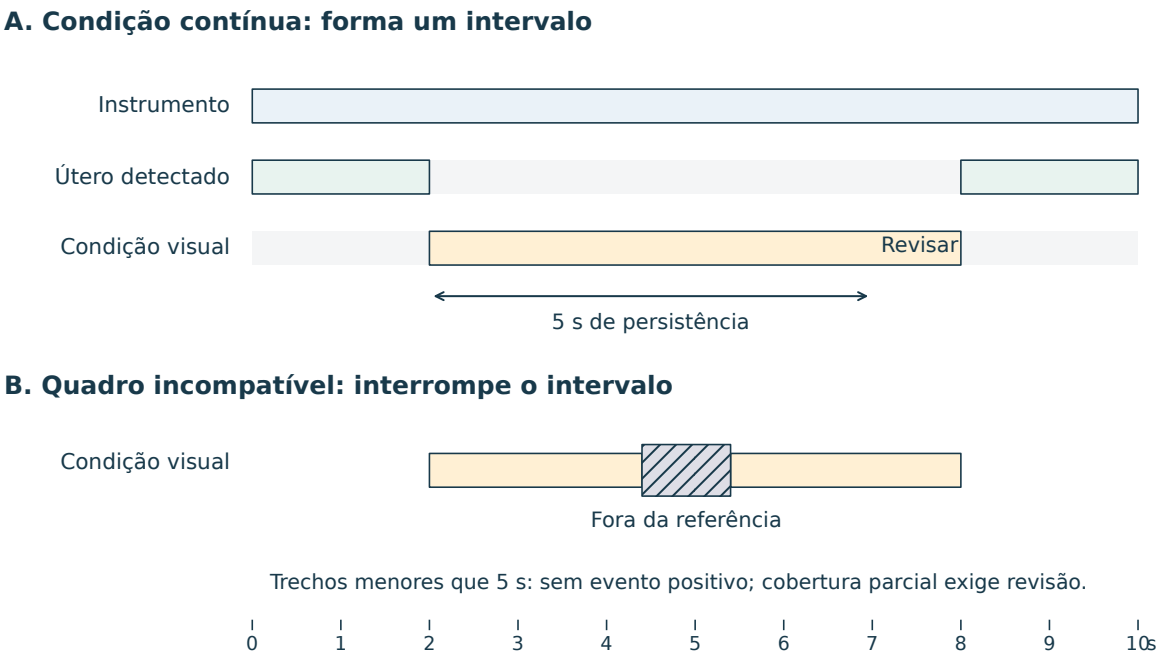


Figura 3: Esquema ilustrativo da regra temporal, sem medir desempenho clínico. No cenário A, a condição persiste por tempo suficiente; no B, um quadro incompatível interrompe a sequência. Ausência de evento positivo não elimina a necessidade de revisão da cobertura.

A nova execução utilizou YOLOv8s, resolução de 416 por 416 pixels, batch 8, até 80 épocas e paciência 20. Foram concluídas 80 épocas, em 27,12 minutos de treinamento na GPU NVIDIA GeForce RTX 2060. A seleção usa somente a validação do primeiro prefixo de clipe.

Conjunto	Imagens	mAP50	mAP50–95
Validação	74	0,941	0,620
Teste	37	0,980	0,615
Reserva de clipe	60	0,613	0,299

As métricas acima pertencem à nova execução e não são diretamente comparáveis ao mAP50 histórico: partições, preparação de anotações, batch e ambiente são diferentes. A queda de mAP50 do teste (mesmo prefixo do treino) para a reserva mostra que o valor alto no desenvolvimento não se mantém na outra origem disponível. Isso é compatível com diferenças de domínio e similaridade temporal, sem identificar uma causa única. A reserva não participou do treino, da escolha de limiares ou do checkpoint. O resultado entre prefixos não é validação em pacientes independentes.

Precisão e recall presentes no JSON são resumos de objetos da avaliação padrão Ultralytics. Não são os índices da regra temporal com limiares 0,4/0,6, cuja referência e resultados são registrados separadamente.

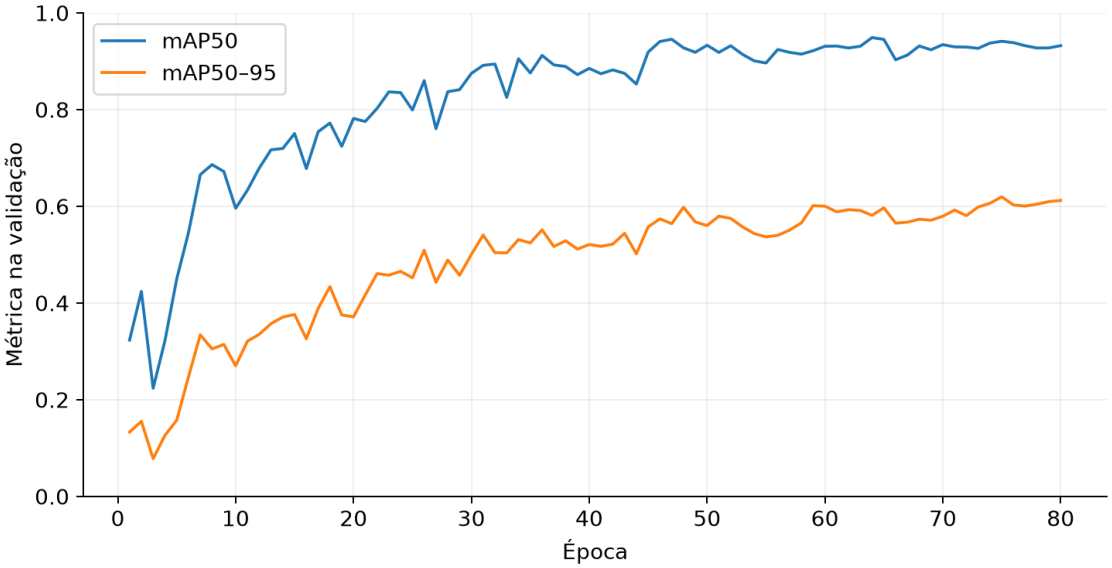


Figura 4: Evolução da validação no novo treino YOLOv8s; a reserva de clipe não participa da curva.

O peso congelado possui SHA-256 iniciado por `efe5cc2588300eea`. Evidências em `evidence/video_reproducao.json` e `evidence/video_dataset_auditoria.json`.

A montagem reservada foi construída após congelar o modelo, com 60 quadros-fonte não usados no desenvolvimento e duração de 120,0 segundos. A inferência gerou 0 evento(s). A referência temporal deriva das caixas anotadas e da própria regra de montagem; não é anotação clínica de complicações. A integração usa o teste para o exemplo positivo e mantém a reserva como verificação separada, com seus intervalos não pareados.

Montagem	Referência	Sinalizados	Pareados	Sem pareamento
Teste	3	2	2	1
Reserva	2	0	0	2

Os intervalos são pareados uma única vez com IoU temporal de pelo menos 0,5. No teste, dois de três intervalos derivados das caixas foram recuperados (precisão 1,00 e recall 0,667). Na reserva, os dois intervalos não foram recuperados: recall 0 e precisão não definida. São índices de concordância com uma referência construída, não sensibilidade clínica. Não foi confirmada a exaustividade das anotações; ausência de caixa não comprova ausência anatômica. A divergência exige revisar tanto rótulos quanto detecções. Os limiares operacionais continuam 0,4/0,6.

6.2 Anotações, calibração e compatibilidade visual

A revisão separou três questões: concordância com caixas anotadas, detecção temporal e interpretação clínica. Nos oito quadros-fonte que compõem os dois intervalos esperados da reserva, o modelo identifica instrumento e também útero sem caixa correspondente. Isso

bloqueia o alerta, mas não comprova isoladamente erro anatômico do modelo: pode haver detecção espúria ou marcação incompleta. As anotações e o peso foram preservados.

Uma busca declarada de 30 pares de confiança utilizou exclusivamente as 74 imagens de validação. O alvo é a condição por quadro anotado (instrumento com útero não anotado), e o desempate favorece a configuração original. A duração de cinco segundos e a tolerância de um segundo não são ajustadas pela montagem.

Conjunto	Original (0,4/0,6)	Candidato (0,4/0,4)
Validação	0,934	0,951
Teste	0,967	0,967
Reserva já observada	0,627	0,583

A tabela apresenta macro-F1 por quadro, não por evento. O candidato melhora a validação, mas piora na reserva conhecida; não foi promovido. Após observar a reserva, essa investigação é posterior à avaliação original e não constitui nova verificação cega.

Foi acrescentada uma verificação de compatibilidade visual por mediana e MAD de duas características globais: proporção de tons quentes e diferença média vermelho–azul. A referência utiliza somente 776 imagens de treino. O menor limite na grade 4/6/8/10 que retém ao menos 95% da validação é escolhido sem imagens externas. O limite selecionado foi 4, retendo 74/74 na validação, 37/37 no teste e 60/60 na reserva. Cores não reconhecem anatomia; o filtro pode rejeitar cenas válidas ou reter cenas inadequadas.

Quadros incompatíveis interrompem imediatamente a regra temporal; não são preenchidos como observações normais e não são unidos pela tolerância. A integração conserva cobertura parcial, parâmetros e limitações. Um vídeo sem evento, mas com cobertura parcial, continua na caixa de revisão. Um alerta positivo mantém sua prioridade mesmo com cobertura parcial.

A fonte adicional é o vídeo didático editado *Total Laparoscopic Hysterectomy*, TVASurg, Universidade de Toronto. A mídia não foi usada no ajuste do YOLO nem na escolha de limiares. No intervalo 150–240 segundos, a primeira execução gerou um falso alerta técnico sobre uma ilustração; ele permanece registrado. Após a proteção visual, esse alerta não reapareceu. A correção foi motivada por essa falha externa e não é apresentada como resultado cego.

Trecho da fonte	Quadros	Fora da referência	Sinais
150–240 s	450	73	0
240–330 s	450	33	1

O segundo intervalo (240–330 segundos) foi fixado antes de sua primeira inferência com a referência congelada. É uma reserva temporal do mesmo vídeo/paciente, sem independência clínica. O sinal obtido solicita revisão e não comprova desvio cirúrgico.

Não há rótulos médicos para calcular acurácia nessa fonte. O pré-treino do modelo base não foi integralmente auditado.

As imagens externas continuam privadas, com atribuição e orientação para não republicação sem autorização. O relatório e o Git contêm apenas resultados sanitizados, hashes e a origem. A revisão não retreinou o YOLO nem fez chamadas pagas à API.

6.3 Resultados históricos da equipe

O pacote original registra uma montagem de 114 segundos, 570 quadros e dois intervalos: 76–82 e 84–114 segundos, com confiança média de 0,82 e 0,81. A regra reproduziu esses intervalos a partir das detecções recebidas. Esses registros documentam a frente original; não são métricas do novo modelo. Os índices históricos e sua descrição permanecem em `relatorio/secao_video.md`.

7 Análise textual em nuvem

A transcrição é enviada à API da OpenAI para extrair sentimento, termos relevantes, contexto e trechos literais. O fornecedor substitui os serviços Azure conforme orientação docente registrada em `evidence/orientacao_docente.md`. O formato estruturado é validado antes da integração.

Menções afirmadas, negadas ou incertas permanecem distintas. Contexto histórico ou de terceiros não é interpretado como sintoma atual do paciente. A existência de JSON válido não garante correção semântica; os controles incluem negação, citação e instruções conflitantes no texto. Sentimento e classe acústica não são somados como probabilidades de gravidade clínica.

Modelo utilizado: **gpt-4o-mini (texto) e gpt-4o-mini-transcribe (áudio)**. Chamadas reais registradas: **18**. Custo estimado acumulado: **US$ 0,005980**. Estado registrado: 16 chamadas concluídas; duas respostas rejeitadas sem uso na decisão; inclui reserva conservadora da primeira falha.

As chamadas usam cache, limite local de solicitações e reserva de orçamento. O custo é estimado a partir dos dados de uso, não uma consulta à fatura. As demonstrações da entrega reutilizam respostas salvas; nenhuma chave é necessária para visualizá-las. Novas chamadas são opcionais e a credencial fica em variável de ambiente ou nos Secrets do Colab.

8 Anomalias e monitoramento temporal

8.1 Sinais vitais e movimentação

Uma referência anterior de pelo menos vinte observações é congelada antes de avaliar os novos pontos. Para cada campo, utilizam-se a mediana e a escala robusta baseada no desvio absoluto mediano (MAD):

$$s = 1{,}4826\ \text{mediana}(|x_i - \text{mediana}(x)|), \qquad z = \frac{|x - \text{mediana}(x)|}{s}.$$

A demonstração sinaliza $z \geq 6$. Referências sem dispersão suficiente permanecem inconclusivas. Os campos incluem batimentos, pressão sistólica e diastólica, oxigenação e medidas de movimentação. São limites estatísticos de demonstração, não protocolos assistenciais.

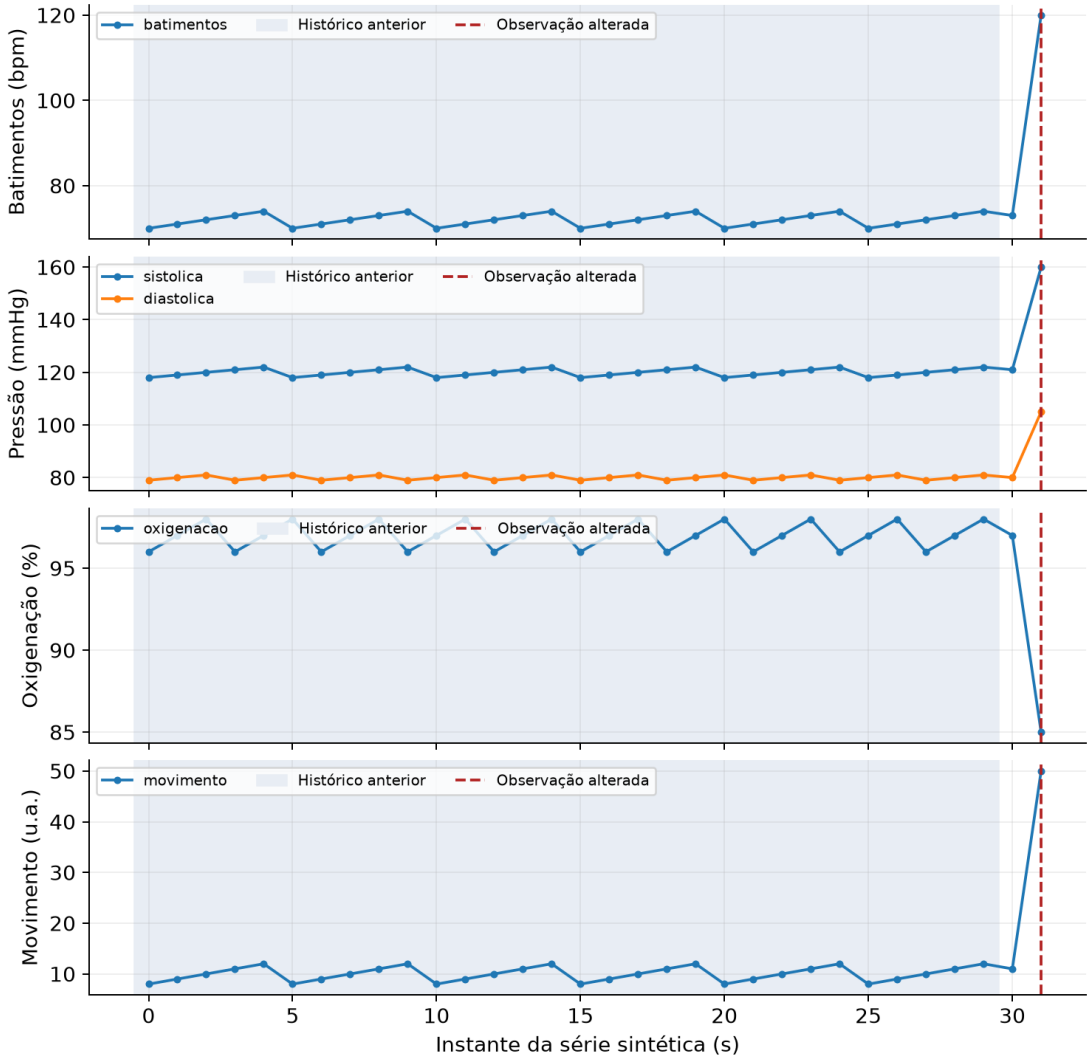


Figura 5: Histórico e alterações sintéticas utilizados na avaliação do monitor estruturado.

8.2 Prescrições

Os registros sucessivos de um medicamento são comparados preservando unidade, via e intervalo. A variação relativa da dose só é calculada quando unidade e via são compatíveis; a demonstração sinaliza variação de pelo menos 50%. Mudanças de unidade, via ou intervalo são descritas separadamente. O detector não recomenda doses ou alterações de tratamento.

8.3 Inferência em mídias e latência

O fluxo óptico denso de Farnebäck mede alterações inespecíficas de movimento entre quadros. Ele não reconhece anatomia ou postura clínica. As referências utilizam apenas observações anteriores. A execução incremental recebe JSONL ou processa amostras de áudio e quadros de arquivos no ritmo original.

Foram criadas seis sínteses novas: duas referências e uma gravação reservada por voz. Não há hashes compartilhados com o corpus de 1.180 WAVs nem com as seis provas externas anteriores. O classificador emocional permaneceu congelado e não participou destes critérios.

Voz	Cenário	Esperado	Obtido
Daniel	Original	Sem sinal	Sem sinal
Daniel	Volume reduzido	Sem sinal	Sem sinal
Daniel	Pausas inseridas	Sinal	Sinal
Daniel	Silêncio	Inconclusivo	Inconclusivo
Maria	Original	Sem sinal	Sem sinal
Maria	Volume reduzido	Sem sinal	Sem sinal
Maria	Pausas inseridas	Sinal	Sinal
Maria	Silêncio	Inconclusivo	Inconclusivo

A versão interrompida insere 380 ms de silêncio a cada bloco de 180 ms. A versão com ganho reduzido multiplica a amplitude por 0,35. São perturbações técnicas, sem rótulo de doença; as derivações da mesma fonte não são observações independentes.

Dois vídeos geométricos novos passaram pelos cálculos reais de fluxo óptico: o controle não gerou eventos e o cenário alterado gerou 2. Não foi usado oráculo de caixas ou classes. Na montagem recebida foram processados 570 quadros e não houve aumento persistente que atingisse essa regra. Isso não significa ausência de eventos clínicos.

A reprodução contínua no ritmo original analisou 89 pares de quadros em 17,83 s de parede. Foram avaliadas 3 janelas de voz e persistidas 6 transições com sinais. O percentil 95 de processamento foi 15,20 ms por passo, além da espera da janela de cinco segundos. Não inclui ASR, nuvem ou captura clínica.

Evidência: `evidence/midias_complementares.json`. Nenhuma chamada paga foi feita nesta complementação.

A espera da janela de áudio é de cinco segundos. As medições locais de processamento são separadas dessa espera; não incluem reconhecimento de fala em nuvem, aquisição clínica ou rede hospitalar. A reprodução de resultados prontos mede persistência e entrega, não a inferência dos modelos.

9 Fusão, entrega e revisão

Cada fonte informa origem, estado, alerta, prioridade e limitações. Baixa confiança, indisponibilidade, erro e cobertura parcial são preservados. A maior prioridade válida define o nível do caso, sem cancelar a indicação de modalidades inconclusivas.

A caixa SQLite utiliza transações e uma identidade estável para impedir entregas duplicadas. A confirmação de revisão conserva o responsável e o instante em uma trilha de auditoria. Os relatórios JSON, Markdown e CSV são gravados de forma atômica. O painel HTTP se vincula a `127.0.0.1` e demonstra revisão local, sem comunicação com um hospital.

Composição revisada em integracao/evidencias/revisao_final_20261111; áudio novo-03, texto real em cache, novo YOLO em montagem de teste e fontes estruturadas sintéticas. Cobertura parcial de vídeo preservada. Dois controles externos verificam fila de revisão mesmo sem alerta positivo. No caso integrado, a confiança acústica do áudio novo-03 é 0,595, inferior ao limiar 0,70. A fonte de áudio fica inconclusiva e a cobertura permanece incompleta; o alerta alto do vídeo é preservado. A cobertura depende da validade de cada fonte, além da disponibilidade dos arquivos.

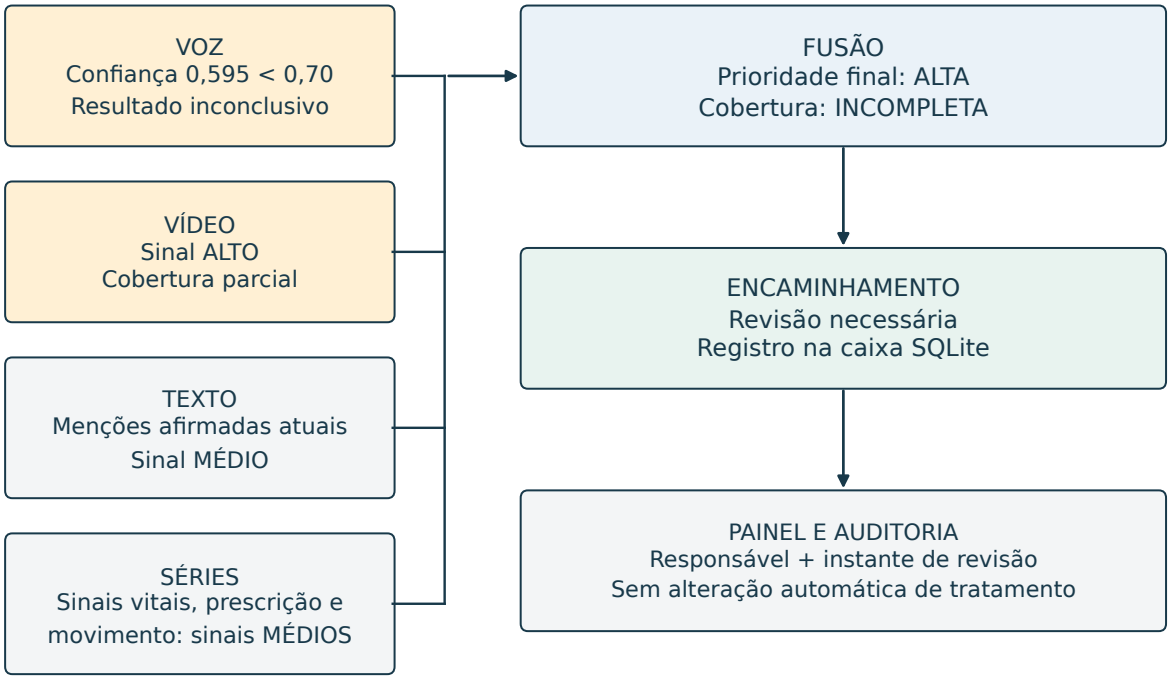


Figura 6: Decisão do caso integrado registrado. O sinal alto de vídeo é preservado, enquanto baixa confiança e cobertura parcial mantêm o caso incompleto. A associação de fontes é didática e exige revisão humana.

Os registros completos da reprodução e da entrega estão em `integracao/evidencias/revisao_final_20261111/replay.json` e `integracao/evidencias/revisao_final_20261111/entrega_auditoria.json`.

No monitor incremental foram processados 32 pacotes. Latência local média: 0,631 ms; percentil 95 (posto mais próximo): 0,928 ms; máxima: 4,598 ms. O intervalo inclui detector estatístico, fusão e SQLite, conforme a instrumentação do monitor.

Os controles também verificam vídeo sem evento positivo e com cobertura parcial: o caso permanece na fila. No controle positivo, a prioridade alta é mantida. A confirmação automática de teste é identificada como demonstração, sem atribuir revisão clínica a um profissional.

10 Verificação e reprodução

Suíte **pytest Python 3.12; verificação de entrega**: 106 verificações aprovadas, 0 falhas.

Também foram aprovadas 26 verificações parametrizadas adicionais (subtestes), registradas separadamente da contagem de testes.

A suíte cobre contratos, prioridade, dados ausentes, validade temporal, pressão arte-

rial, comparações de prescrições, concorrência, entrega idempotente, cache, orçamento e interrupção da regra visual. O painel foi verificado por GET e confirmação POST com persistência da auditoria. Os testes de software não substituem avaliação do desempenho clínico.

10.1 Notebooks e ambiente

Os três notebooks são distribuídos com saídas salvas de execução local, compatíveis com Google Colab. O notebook de áudio recalcula previsões com o modelo congelado; vídeo apresenta métricas de treinamento e inferência registradas; integração executa fusão, detectores estruturados, relatórios e painel. Gráficos e tabelas distinguem essas etapas. Não há novo ajuste ou chamada paga no modo padrão.

Experimentos: GPU local NVIDIA RTX 2060. Notebooks de apresentação executados em CPU, com modelo de áudio congelado e resultados de vídeo registrados; sem treinamento, Colab ou chamadas pagas nesta etapa. GPU utilizada neste estudo: sim. Sessão de computação encerrada ao final: sim.

O código está organizado em pacote comum, módulos de áudio/vídeo, scripts e testes. As partições, os hashes e as versões dos artefatos permitem repetir os experimentos. Os arquivos de entrada privados e o peso YOLO ficam no backup da equipe, com instruções de restauração em `DATASETS_E_MODELOS.md`. Experimentos antigos permanecem identificados como históricos.

1. Preparar Python e instalar as dependências descritas no README.
2. Executar `python -m pytest -q` para a suíte de software.
3. Executar `python scripts/run_demo.py -help` para conferir entradas e diretório de saída.
4. Informar o CSV regenerado, o JSON de vídeo e o resultado textual real ao script de demonstração.
5. Abrir o painel com `python -m techchallenge4.dashboard -help` e selecionar o banco gerado.
6. Compilar o relatório com `python relatorio/gerar_relatorio.py -compile -package` ou importar o ZIP no Overleaf.

11 Limitações e conclusão

O projeto demonstra o fluxo multimodal e a entrega local de sinais para revisão. O corpus sintético não representa diversidade de pacientes, condições médicas ou ambientes. A

reserva por frase reduz similaridade textual, mas não estabelece independência de locutor. Os controles acústicos verificam pausas e trechos vocais, sem medir sensibilidade para uma condição médica.

No vídeo, os dois intervalos derivados de caixas da reserva continuam sem pareamento. A ausência de caixa anotada não confirma ausência do órgão, e uma anotação independente deve distinguir presença, ausência confirmada e visibilidade inconclusiva. A fonte didática externa não possui rótulos clínicos para calcular acurácia; a proteção de aparência corrige um falso alerta técnico, mas não comprova detecção confiável de falhas cirúrgicas.

As modalidades não são sincronizadas por paciente; valores estruturados e controles de apresentação são sintéticos. As decisões exigem contexto e revisão humana. O sistema não altera condutas, e as medições de latência não demonstram funcionamento em um hospital. Essas restrições delimitam os resultados e orientam uma avaliação futura com dados anotados de outras origens.

12 Referências

[1] FIAP. *IADT – Fase 4 – Tech challenge*. Enunciado, páginas 2–4, 2026.

[2] FIAP. *Análise de vídeo, áudio e texto*; *Integração e automação com a API da OpenAI*. Materiais da Fase 4, 2026.

[3] Machinelearning. *Uterus Dataset*, versão 4. https://universe.roboflow.com/machinelearning-yekk6/uterus-qn1he/dataset/4.

[4] TVASurg, Universidade de Toronto. *Total Laparoscopic Hysterectomy*. https://pie.med.utoronto.ca/TVASurg/project/gyn-tlh/.

[5] OpenAI. *Structured model outputs*. https://developers.openai.com/api/docs/guides/structured-outputs.

[6] OpenAI. *Whisper*. https://github.com/openai/whisper.

[7] Librosa. *Feature extraction and pYIN*. https://librosa.org/doc/latest/.

[8] Scikit-learn. *RandomForestClassifier; model persistence*. https://scikit-learn.org/stable/.

[9] Ultralytics. *YOLOv8 documentation*. https://docs.ultralytics.com/models/yolov8/.

[10] OpenCV. *Optical Flow*. https://docs.opencv.org/4.x/d4/dee/tutorial_optical_flow.html.

A Manifesto de evidências

Artefato	SHA-256 (prefixo)
evidence/video_dataset_auditoria.json	8f14126d114c5190
evidence/video_reproducao.json	e267cdb305d3734d
evidence/video_calibracao.json	8a213305e9cb1a85
evidence/video_diagnostico.json	82c54397cc1ad66b
artifacts/video/referencia_visual.json	e06eec5f5fca1f1b
evidence/video_cobertura_externa.json	e0d74a51226c8003
evidence/video_cobertura_protocolo.json	cced71fcb2f21956
evidence/video_integracao_revisao.json	c42d69df5abda281
evidence/video_inferencia_nova.json	149d0b27e28a2d68
artifacts/video/manifesto_video.json	ca6187addfca1461
evidence/midias_complementares.json	4a1ad23c210416af
evidence/padrao_relatorio.json	dce7f0f2b99dd414
evidence/audio_reproducao.json	eec78c6135392737
audio/evidencias/particoes_audio.csv	30dc41d77d9167b3
audio/evidencias/predicoes_avaliacao.csv	a6b46c44b1312d97
artifacts/audio/manifesto_audio.json	fafd4dbbe961e037
evidence/resumo_execucao.json	218e23352c018d82
evidence/audio_externo_transcricoes.json	8da6101b626df962
evidence/asr_comparacao.json	c86c4ff64c6c6263
evidence/audio_externo.json	20d055c33a303003
evidence/audio_recebido_drive.json	99a156e55c61acef
evidence/openai_validacao.json	9e43f13d89c3dc42
evidence/video_validacao.json	17832e5417cf354e
evidence/dashboard_validacao.json	e994518026d1aa81
integracao/evidencias/monitoramento_final/ monitoramento_resumo.json	20c95ef1eec67a2b
integracao/evidencias/revisao_final_20261111/ replay.json	4c41c70cc3c53b47
integracao/evidencias/revisao_final_20261111/ entrega_auditoria.json	341ad38886b9c194
integracao/evidencias/revisao_final_20261111/ anomalias_estruturadas.json	e5e6f55892ed79b8

Os hashes completos devem ser consultados nos manifestos de execução e no histórico do repositório. O prefixo serve como referência de leitura, não como substituto de uma verificação integral.