FIAP

Faculdade de Informática e Administração Paulista

Pós Tech - Inteligência Artificial para Devs

Tech Challenge | Fase 4

Monitoramento multimodal em saúde da mulher

Integração de áudio, vídeo e texto
com detecção de anomalias e alertas auditáveis

Integrante	**RM**
Benicio Antonio Cardoso	371527
Marcelo Viana de Araújo	372707
Nirton Afonso de Oliveira Filho	370221
Valkiria Nonato de Faria	373256

Relatório técnico e evidências de reprodução

Versão consolidada | 10 de novembro de 2026

Código e artefatos: branch `Nirton`

Resumo

Este trabalho apresenta um protótipo de monitoramento multimodal com recorte em saúde da mulher. A solução combina características acústicas de falas sintéticas, eventos de perda de visualização de uma área crítica em vídeos laparoscópicos e análise textual por serviço gerenciado de inteligência artificial. Um contrato comum preserva a origem, a disponibilidade e a prioridade de cada evidência. O resultado alimenta relatórios automáticos e uma caixa de alertas local, com registro de entrega e confirmação de leitura.

A frente de áudio utiliza Whisper, Librosa e Random Forest. A frente de vídeo reaproveita o detector YOLOv8 de instrumentos e útero desenvolvido pela equipe. A integração inclui detectores demonstrativos para séries temporais de sinais vitais e movimentação e para alterações sucessivas em prescrições. A análise textual e a transcrição dos WAVs novos são realizadas por APIs da OpenAI, substituição de fornecedor autorizada pelo professor; Whisper permanece na representação acústica. O texto é analisado para sentimento e menções relevantes. O processamento incremental é demonstrado por reprodução temporal de eventos; as medidas de latência abrangem a persistência local do alerta, não toda a inferência nem uma operação hospitalar.

O protocolo distingue avaliações de desenvolvimento, teste e verificação cega. As famílias de gravações reservadas para a verificação final não participam do ajuste do novo classificador. Métricas anteriores publicadas pela equipe são identificadas como históricas e não substituem os resultados reproduzidos nesta versão. Os dados sintéticos, a ausência de um conjunto clínico pareado e as limitações de proveniência do vídeo restringem as conclusões à viabilidade técnica do fluxo.

Palavras-chave: inteligência artificial multimodal; análise de áudio; visão computacional; processamento de linguagem natural; anomalias; rastreabilidade.

Como ler as evidências

Executado
Há registro de execução e saída verificável nesta consolidação.

Relatado pela equipe
Resultado preservado de material da frente responsável; não significa nova medição.

Sintético ou controlado
Cenário construído para verificar comportamento de software, sem validação clínica.

Limitação
Condição que impede uma conclusão mais ampla, explicitada na seção correspondente.

Sumário

Resumo **i**

1 Problema, objetivo e escopo **1**

2 Arquitetura e organização da solução **2**

3 Dados, proveniência e controle de versões **3**

4 Processamento e avaliação de áudio **4**

5 Isolamento de dados e verificação cega **5**

6 Análise de vídeo e regra temporal **7**

7 Análise textual gerenciada e controle de custos **8**

8 Detecção de anomalias estruturadas **9**

9 Fusão multimodal e contrato por caso **10**

10 Monitoramento incremental e entrega de alertas **11**

11 Protocolo de testes e resultados reproduzidos **12**

12 Resultados de vídeo e análise dos casos **13**

13 Reprodutibilidade, execução e organização **14**

14 Matriz de atendimento ao desafio **15**

15 Limitações, riscos de validade e evolução **16**

16 Conclusões e material para demonstração **17**

Referências **18**

A Manifesto de evidências e critérios de auditoria **19**

B Auditoria final de conformidade com o enunciado **20**

1 Problema, objetivo e escopo

O desafio propõe ampliar uma solução clínica para analisar texto, áudio e vídeo, detectar alterações fora do padrão e apoiar o monitoramento preventivo. O enunciado requer análise de vídeos clínicos, processamento de voz, análise textual, detecção de anomalias em dados estruturados e geração de alertas. As entregas são o código completo, o relatório técnico e uma demonstração em vídeo de até 15 minutos.

O recorte da equipe reúne vídeos de laparoscopia ginecológica e falas sintéticas com configurações de prosódia associadas a ansiedade/hesitação, neutralidade e tristeza. O sistema registra sinais de triagem e solicita revisão humana. Não recomenda tratamento e não converte confiança de modelo em probabilidade de doença.

1.1 Objetivos técnicos

1. Preservar as implementações de áudio e vídeo, com uma interface única e verificável.
2. Incorporar análise textual em nuvem sem incorporar credenciais ao repositório.
3. Demonstrar anomalias em sinais vitais, prescrições e movimento por entradas temporais documentadas.
4. Entregar alertas a uma interface local, mantendo evidência da persistência e do reconhecimento de leitura.
5. Reproduzir a avaliação com isolamento de dados, registrar versões e separar resultados técnicos de inferências clínicas.

1.2 Interpretação do uso de nuvem

O PDF original cita Azure Speech to Text e Azure Text Analytics. Em esclarecimento de 9 de novembro de 2026, apresentado pelo integrante responsável pela integração, o professor Wagner Santos autorizou serviços alternativos, inclusive OpenAI, e explicou que Azure é sugestão. Esta versão utiliza a equivalência funcional: Whisper local para a representação acústica, transcrição gerenciada pela OpenAI para os novos WAVs e análise textual pela OpenAI. A síntese original das falas com Azure é registrada como etapa de construção do dataset, não como execução de Speech to Text.

1.3 Responsabilidades

Frente	**Responsável e contribuição**
Áudio	Valkiria: dataset, transcrição, características e classificador.
Vídeo	Marcelo: detector YOLOv8 e regra temporal de perda de visualização.
Integração	Nirton Afonso: fusão, nuvem, alertas, reprodução e documentação consolidada.
Demonstração	Benicio: gravação, edição e publicação do vídeo final.

2 Arquitetura e organização da solução

As modalidades são processadas por componentes distintos e convergem em um contrato de evidências. A separação permite reutilizar resultados já produzidos, executar cada modelo isoladamente e identificar fontes que falharam. Uma falha de reconhecimento não é convertida artificialmente em áudio neutro ou ausência de risco.

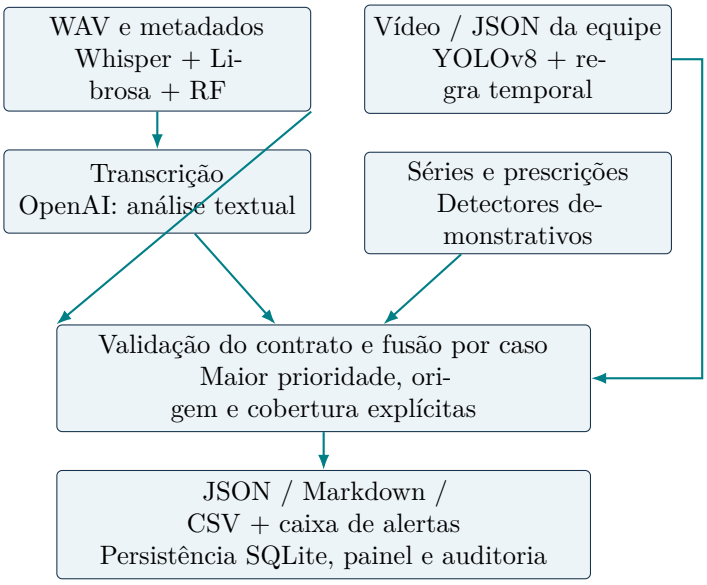


Figura 1: Fluxo lógico da integração. As fontes disponíveis não constituem uma coorte clínica pareada.

2.1 Camadas

Entradas e proveniência
Caminhos, identificadores, hashes, timestamps e indicação de origem sintética ou de artefato da equipe.

Processamento por modalidade
Inferência acústica, importação de eventos de vídeo, análise textual e comparação de observações estruturadas.

Fusão e regras
Normalização das saídas, preservação da maior prioridade e representação das fontes inconclusivas.

Entrega
Relatórios por caso, resumo de lote, caixa persistente de alertas e confirmação de revisão no painel local.

Evidências
Resultados dos testes, métricas, partições, contagem de arquivos e custos das chamadas de nuvem.

3 Dados, proveniência e controle de versões

3.1 Áudio

O conjunto corrigido contém 1.180 WAVs e 1.180 linhas de metadados, distribuídos entre 380 exemplos de ansiedade/hesitação, 400 neutros e 400 de tristeza. Há 295 gravações originais, com quatro versões por gravação: original, lenta, rápida e com ruído. As falas foram produzidas por síntese de voz e aumento de dados.

A versão anterior usava o nome nominal de 1.200 arquivos e um CSV com essa quantidade. A consolidação considera o conteúdo efetivo do ZIP corrigido. O nome do arquivo não é usado como evidência suficiente da quantidade; a contagem e os identificadores são auditados.

Os artefatos corrigidos do Drive também foram obtidos e auditados: o CSV da autora contém 1.180 linhas e nenhum nome ausente no dataset. O modelo recebido, ajustado com todo o conjunto, é preservado como artefato histórico. A avaliação independente deste relatório usa outro modelo, regenerado somente com os 712 exemplos de treino. Os hashes e a auditoria constam em `evidence/audio_recebido_drive.json`.

Classe de origem	WAVs	Participação
Ansiedade/hesitação	380	32,2%
Neutro	400	33,9%
Tristeza	400	33,9%
Total	1.180	100%

Tabela 1: Distribuição do dataset sintético corrigido. Rótulos construídos para experimento técnico.

3.2 Vídeo

O detector da equipe foi desenvolvido sobre Uterus Dataset v4, disponibilizado no Roboflow Universe sob indicação de licença CC BY 4.0. A divisão relatada é de 1.197 imagens de treino, incluindo aumentos, 114 de validação e 57 de teste; a biblioteca avaliou 56 imagens válidas no teste. Os quadros têm origem em vídeos de terceiros e não são redistribuídos neste relatório.

O pacote recebido contém o JSON de resultado, o relatório automático, imagens de eventos e o vídeo anotado. Esses artefatos permitem verificar o consumo da saída real da frente de vídeo. Não demonstram, isoladamente, generalização a um novo procedimento.

3.3 Demais entradas

As séries de sinais vitais e movimentação e os registros de prescrição usados na demonstração são sintéticos. Seus timestamps permitem verificar ordem de chegada, cálculo de desvios, entrega e revisão de alertas. Não foram obtidos dados de pacientes para esta consolidação.

4 Processamento e avaliação de áudio

4.1 Representação acústica

O WAV é convertido para mono, com taxa de 16 kHz. O Whisper tiny produz a transcrição em português. O Librosa extrai seis características numéricas que alimentam o Random Forest. Manter essa representação é necessário para não trocar, sem avaliação, a entrada usada no treinamento.

Característica	**Definição operacional**
Duração	Quantidade de amostras dividida pela taxa de amostragem.
Energia média	Média da energia RMS calculada em janelas.
Proporção de pausas	Duração fora dos intervalos sonoros, com `top_db=30`, dividida pela duração.
Ritmo de fala	Número de palavras transcritas dividido pela duração em minutos.
Tom médio	Média dos valores válidos de F0 estimados por pYIN.
Variação do tom	Desvio padrão dos valores válidos de F0.

4.2 Classificador e confiança

É utilizado Random Forest com 200 árvores, semente fixa e balanceamento de classes. A saída inclui classe e `predict_proba`. Esse valor é uma estimativa interna do classificador. Não é uma confiança clínica calibrada.

A detecção de silêncio, arquivos inválidos e transcrições vazias evita que uma falha operacional seja tratada como normalidade. A integração aplica um limiar de confiança configurável para decidir se há evidência acústica utilizável. Esse limiar é demonstrativo e não foi validado para triagem assistencial.

As métricas do classificador são calculadas sobre sua classe prevista, enquanto a integração também pode se abster por confiança inferior a 0,70. A acurácia de classificação não é, portanto, a taxa de decisões conclusivas da integração. Uma previsão correta com baixa confiança pode continuar inconclusiva para o fluxo de alerta.

4.3 Separação entre reprodução e generalização

Classificar novamente o dataset com um modelo ajustado em todos os seus exemplos verifica o funcionamento do software e gera o CSV de resultados. Essa execução não mede generalização. Para avaliação independente do novo modelo, o ajuste é restrito à partição de treino, com conjuntos reservados separados e manifestos explícitos.

As classes são descrições do experimento de prosódia. O trabalho não demonstra detecção de fadiga, disartria, depressão ou insuficiência respiratória em pacientes reais.

5 Isolamento de dados e verificação cega

A versão original da avaliação agrupava as quatro variações de cada gravação, impedindo que original e versão aumentada fossem distribuídos entre treino e teste. Entretanto, a reutilização das mesmas frases-base em gravações diferentes ainda permite semelhança textual entre conjuntos.

Na reprodução consolidada, a unidade de separação é a família da frase-base. O manifesto atribui cada família a uma única partição, preservando suas gravações e aumentos no mesmo conjunto. Os parâmetros do Random Forest são fixados antes da verificação cega.

Partição	Famílias previstas	Uso
Treino	12	Ajuste das árvores e de operações dependentes de dados.
Validação	3	Observação do comportamento sem incluir no ajuste final.
Teste	3	Avaliação técnica reservada do modelo congelado.
Verificação cega	2	Última verificação, separada das três partições anteriores.

As quantidades efetivamente reservadas são 712 WAVs de treino, 172 de validação, 176 de teste e 120 de verificação cega. O arquivo de partições conserva o identificador da gravação original e a família de frase-base, permitindo conferir a distribuição antes do ajuste.

5.1 Verificações de não sobreposição

- Cada arquivo tem identificador e hash. Não pode constar em duas partições.
- Uma gravação original e seus aumentos permanecem juntos.
- Uma família de frase-base pertence a uma única partição.
- O modelo usado na verificação cega não é reajustado com exemplos reservados.
- As métricas da verificação cega são publicadas separadamente, sem escolher a melhor semente depois de observá-las.

5.2 O significado de “inédito”

As gravações reservadas não são vistas pelo novo classificador no ajuste, na validação ou no teste. Elas continuam pertencendo ao mesmo domínio sintético e à mesma voz de origem. Portanto, o protocolo melhora o isolamento experimental, mas não equivale a uma validação externa com novos pacientes, novos locutores e novos ambientes.

As 120 versões do conjunto cego não são 120 observações clínicas independentes: há aumentos de gravações e somente duas famílias textuais reservadas. A acurácia e o F1 descrevem esse conjunto técnico. Intervalos estatísticos que tratassem todos os WAVs como amostras independentes poderiam subestimar a incerteza.

O Whisper é pré-treinado e sua base completa de pré-treinamento não é auditável nesta entrega. A afirmação de isolamento refere-se ao treinamento supervisionado local do classificador e aos conjuntos controlados pelo projeto.

5.3 Gravações novas e erros de transcrição

Além das famílias reservadas, foram criados seis WAVs novos com textos próprios e vozes Microsoft Daniel e Microsoft Maria Desktop, distintas da voz usada na origem do corpus. Seus hashes e textos de referência são registrados. As gravações não são incorporadas ao ajuste do classificador. Como não há anotação emocional independente, suas previsões não são convertidas em acurácia emocional.

O Whisper tiny foi executado nesses seis arquivos. O registro de ASR contabiliza 13 erros de palavra em 109 palavras de referência, WER agregado de 11,9% segundo a normalização do script. No caso novo-03, "falta de ar" foi transcrito como "falta de área". O erro é preservado na evidência; não se substitui silenciosamente a transcrição pelo texto de referência. Esse caso mostra como a qualidade do ASR pode alterar a análise textual posterior. O resultado completo está em `evidence/audio_externo_transcricoes.json`.

Os mesmos WAVs também foram enviados ao modelo `gpt-4o-mini-transcribe`, verificando igualdade dos hashes antes da comparação. A tokenização usa normalização NFC, ignora caixa e pontuação e preserva acentos. Nessa pequena amostra, a API produziu zero erros de palavra, corrigindo a expressão do caso novo-03. O resultado não estima desempenho em pacientes nem permite concluir superioridade geral do serviço.

Transcritor	**WAVs**	**Erros / palavras**	**WER agregado**
Whisper tiny local	6	13 / 109	11,9%
OpenAI mini-transcribe	6	0 / 109	0,0%

O ritmo usado pelo classificador acústico permanece calculado com Whisper, preservando a representação do treinamento. A transcrição da API é uma evidência adicional de comparação e pode alimentar a análise textual sem alterar silenciosamente as características do modelo. A comparação completa está em `evidence/asr_comparacao.json`.

Aplicado o classificador congelado aos seis WAVs novos, todas as previsões foram da classe neutro, com confianças entre 0,50 e 0,60. Como o limiar de integração é 0,70, as seis saídas foram consideradas **inconclusivas**, não evidências de neutralidade. Não há rótulos emocionais validados para calcular acurácia externa. A baixa confiança com vozes diferentes explicita a limitação de generalização. O caso integrado mantém essa indicação sem reduzir o alerta alto do vídeo. A evidência está em `evidence/audio_externo.json`.

6 Análise de vídeo e regra temporal

O detector YOLOv8s da equipe foi ajustado a partir de pesos COCO para duas classes: instrumentos e útero. A documentação registra resolução de 416×416, até 80 épocas, batch 16 e parada antecipada com paciência 20, em GPU T4 no Colab.

6.1 Construção do evento

A regra identifica a presença de instrumento com confiança mínima de 0,4 e ausência de útero detectado com confiança mínima de 0,6. A condição precisa persistir por pelo menos 5 segundos, tolerando interrupções curtas de até 1 segundo. O limiar específico da área crítica procura reduzir falsos positivos de útero que poderiam ocultar eventos.

Prioridade	**Regra operacional da frente de vídeo**
Baixa	Evento a partir de 5 segundos.
Média	Maior evento a partir de 10 segundos.
Alta	Maior evento a partir de 15 segundos ou pelo menos três eventos.
Nenhuma	Ausência de evento que satisfaça as condições.

6.2 Artefato integrado

O pacote do Marcelo registra duração de 114 segundos, 570 quadros analisados e dois intervalos de perda de visualização: 76–82 segundos e 84–114 segundos. O segundo evento tem 30 segundos e preserva a prioridade alta na fusão. As confianças médias registradas são 0,82 e 0,81.

6.3 Verificação executada nesta consolidação

O vídeo anotado foi decodificado integralmente: 570 quadros, 5 FPS e 114 segundos. A aplicação da regra temporal às detecções por quadro fornecidas pela equipe reproduziu os intervalos 76–82 e 84–114 segundos. Essa verificação confirma o processamento dos artefatos, sem executar novamente o detector YOLO.

Foram gerados dois clipes sintéticos inéditos, de 8 e 18 segundos. Um oráculo de marcadores coloridos forneceu detecções controladas para verificar decodificação, amostragem, duração dos eventos, nível de alerta, exportação e fechamento de recursos. O cenário normal produziu nível nenhum e o cenário de 18 segundos produziu nível alto, conforme esperado. O oráculo não é um detector anatômico e esses resultados não medem desempenho do YOLO. A evidência está em `evidence/video_validacao.json`.

6.4 Limites da interpretação

O vídeo de avaliação é uma montagem de imagens do dataset, com dois segundos por imagem, não uma cirurgia contínua independente. Perda de visualização pode ocorrer em situações normais. A regra mede uma condição visual observável e solicita revisão; não demonstra uma complicação cirúrgica.

A proveniência por clipe e a possível proximidade de quadros entre conjuntos limitam a independência das métricas históricas. Uma avaliação realmente externa exigiria vídeo de origem conhecida, fora do dataset, e anotações de referência adequadas.

7 Análise textual gerenciada e controle de custos

A transcrição alimenta a API da OpenAI para extrair sentimento, menções relevantes, contexto e trechos literais de evidência. O resultado segue um esquema estruturado. A análise deve preservar negação e incerteza, vincular cada menção a um trecho da transcrição e evitar inferir informações ausentes.

7.1 Contrato de saída e evidência

O esquema limita os campos esperados e diferencia menção afirmada, negada ou incerta. A integração verifica a estrutura e usa os trechos retornados como evidência de origem textual. Um JSON bem formado não garante correção semântica; por isso os testes incluem pares com negação e instruções conflitantes inseridas no texto.

Os controles textuais verificam a decisão de alerta e o contexto das menções. Eles não constituem uma avaliação rotulada do sentimento. A classificação de sentimento é preservada para inspeção e não determina, sozinha, gravidade ou diagnóstico.

Entrada de verificação	**Comportamento esperado**
“Estou com falta de ar.”	Preservar a menção afirmada e o trecho literal.
“Não estou com falta de ar.”	Preservar a negação; não transformar em sintoma afirmado.
“Talvez eu tenha sentido tontura.”	Manter a incerteza.
Texto sem menção relevante	Devolver ausência de menções sem inventar conteúdo.

7.2 Credenciais e orçamento

A chave é lida do ambiente local ou dos Secrets do Colab. O arquivo de credenciais não compõe o código, os exemplos, os logs, o ZIP do Overleaf ou o pacote de entrega. A execução limita tamanho de entrada e saída, quantidade de chamadas e custo acumulado estimado. O cache evita repetir a mesma consulta.

O gasto registrado é uma estimativa obtida a partir do uso retornado pela API e da tabela de preços declarada no código. A cobrança efetiva deve ser confirmada no painel da conta. A transcrição local com Whisper não consome créditos de transcrição da API.

7.3 Resultado desta consolidação

Modelo utilizado: **gpt-4o-mini (texto) e gpt-4o-mini-transcribe (áudio)**. Chamadas reais registradas: **18**. Custo estimado acumulado: **US$ 0,005980**. Estado registrado: 16 chamadas concluídas; duas respostas rejeitadas sem uso na decisão; inclui reserva conservadora da primeira falha.

As instruções encontradas no texto de entrada são tratadas como dados a analisar. Não autorizam envio a terceiros, mudança de regras, execução de código ou inclusão de diagnósticos.

8 Detecção de anomalias estruturadas

8.1 Sinais vitais e movimentação

As funções recebem histórico anterior e observações posteriores do mesmo caso. O valor de referência é a mediana do histórico. A dispersão é estimada pela mediana dos desvios absolutos (MAD), com o fator 1,4826:

$$z_{robusto}(x) = \frac{|x - \text{mediana}(H)|}{1{,}4826\,\text{MAD}(H)}. \tag{1}$$

O limiar demonstrativo é de seis escalas robustas. Histórico insuficiente ou sem dispersão não produz uma normalidade artificial: exige uma decisão explícita de qualidade de dados. As entradas são verificadas quanto a valores finitos, ordem temporal e consistência dos campos declarados.

A demonstração monitora frequência cardíaca, saturação, pressão sistólica, pressão diastólica e uma característica numérica de movimento. Os nomes das variáveis não convertem um limiar estatístico em faixa clínica. A demonstração de movimento utiliza uma série estruturada; não corresponde à estimação de postura por vídeo.

8.2 Evolução de prescrições

Registros sucessivos do mesmo medicamento são comparados. A alteração relativa de dose só é calculada quando unidade e via são compatíveis. Mudanças de unidade, via e intervalo são destacadas separadamente, pois comparar números sem preservar seu significado geraria alertas incorretos.

O limiar de variação de dose é de 50% no cenário demonstrativo. O sistema indica mudança inesperada para conferência. Não julga adequação terapêutica e não modifica prescrições.

8.3 Cenários de verificação

- Série estável e observação próxima ao histórico: não produzir desvio indevido.
- Observação distante do histórico: registrar variável, instante, valor e referência.
- Histórico sem qualidade: solicitar revisão por fonte inconclusiva.
- Mudança de unidade ou via: não calcular porcentagem de dose incompatível.
- Alteração relevante de dose com unidade e via iguais: gerar evidência de mudança.

9 Fusão multimodal e contrato por caso

A fusão combina evidências com semânticas diferentes sem somar probabilidades incompatíveis. A regra preserva o maior nível de prioridade entre os sinais válidos. Assim, áudio neutro não cancela um evento alto de vídeo. Baixa confiança, ausência ou falha de uma modalidade compõem a cobertura do caso.

Campo conceitual	**Significado**
Identificador do caso	Associação explícita entre as entradas da demonstração.
Identificador do resultado	Rastreia o conjunto de evidências e permite evitar duplicação.
Alerta e nível	Existência de sinal válido e maior prioridade operacional.
Revisão necessária	Sinal presente ou fonte inconclusiva que requer conferência.
Cobertura	Fontes esperadas, disponíveis, ausentes ou inválidas.
Proveniência	Origem de arquivo, hash, versão e indicação de simulação.
Entrega	Persistência na caixa local e eventos de confirmação.

9.1 Pareamento e independência das fontes

O identificador usado na demonstração é um vínculo de software. As fontes de áudio e vídeo disponíveis não são observações simultâneas de uma mesma pessoa. A composição é declarada, evitando criar uma trajetória clínica fictícia.

9.2 Falhas e repetição

Os contratos rejeitam valores não finitos, intervalos incoerentes e níveis desconhecidos. As falhas são mantidas no relatório com seu estado de cobertura. Reexecutar um caso não deve produzir cópias indistinguíveis do mesmo alerta. A persistência usa identificador estável e testes verificam a idempotência.

9.3 Saídas

Cada caso produz uma representação JSON e uma leitura Markdown. O lote produz JSONL e CSV. A caixa de alertas mantém os resultados que exigem revisão. O painel mostra o mesmo conteúdo persistido e registra confirmação de leitura, sem depender de um aplicativo de mensagens externo.

10 Monitoramento incremental e entrega de alertas

A solução oferece reprodução de eventos e leitura incremental de arquivo JSONL. No modo de acompanhamento, novos registros anexados ao arquivo são consumidos com limites de tempo ocioso e quantidade de eventos. Cada observação tem timestamp e identificador do caso. O sistema atualiza o histórico, executa os detectores, consolida as evidências e persiste o alerta na caixa local.

10.1 O que é medido

A medida de latência do reprodutor refere-se à persistência local do alerta. No monitor incremental, o intervalo inclui os detectores estatísticos, a fusão e a persistência do pacote. Nenhuma dessas medidas inclui captura de sensor, execução do Whisper, inferência YOLO, envio de áudio em rede ou resposta da API de linguagem.

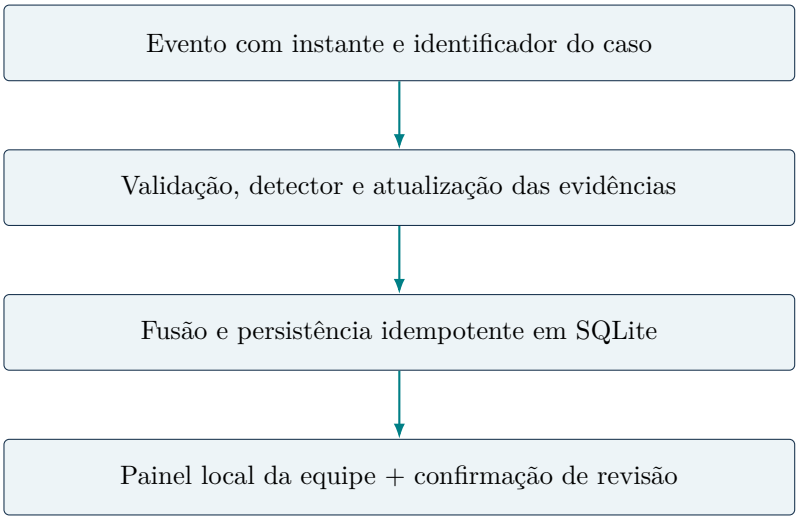


Figura 2: Ciclo de entrega demonstrado localmente. Não representa conexão a um hospital.

10.2 Auditoria da revisão

Um evento de entrega e um evento de confirmação são fatos distintos. O banco registra a criação do alerta; o operador reconhece o item no painel. Essa confirmação mostra o fluxo final da revisão no protótipo, sem afirmar que uma equipe hospitalar real foi notificada.

Os registros completos da reprodução e da entrega estão em `integracao/evidencias/execucao_final/replay.json` e `integracao/evidencias/execucao_final/entrega_auditoria.json`.

No monitor incremental foram processados 32 pacotes. Latência local média: 0,631 ms; percentil 95 (posto mais próximo): 0,928 ms; máxima: 4,598 ms. O intervalo inclui detector estatístico, fusão e SQLite, conforme a instrumentação do monitor.

O monitor foi exercitado com 32 pacotes sintéticos: 30 para construir o histórico, uma observação normal e uma observação alterada de sinais vitais, movimento e prescrição. A execução produziu um alerta persistido. A auditoria detalha a evolução em `integracao/evidencias/monitoramento_final/eventos_processados.jsonl` e resume o cenário em `integracao/evidencias/monitoramento_final/monitoramento_resumo.json`.

11 Protocolo de testes e resultados reproduzidos

11.1 Testes de software

Os testes automatizados verificam comportamento de contrato e de regra: preservação de prioridade, fonte ausente, baixa confiança, validação temporal, comparação de unidades e entrega idempotente. Casos controlados cobrem comportamentos que uma demonstração positiva isolada não exercita.

O teste do adaptador textual utiliza cliente controlado para verificar tratamento de erros, esquema, cache e orçamento sem consumir créditos. As chamadas reais são registradas separadamente, de modo que um teste simulado não seja contado como uso efetivo da nuvem.

Suíte **pytest Python3.12 após auditoria**: 59 verificações aprovadas, 0 falhas.

Também foram aprovadas 26 verificações parametrizadas adicionais (subtestes), registradas separadamente da contagem de testes.

11.2 Avaliação de áudio

A avaliação foi regenerada com partições isoladas por família de frase-base. Os valores abaixo são extraídos de `evidence/audio_reproducao.json`; cada partição é reportada separadamente.

Partição	Exemplos	Acurácia	F1 macro
Validação	172	93,60%	0,933
Teste	176	86,36%	0,862
Verificação cega	120	88,33%	0,883

Matriz de confusão da verificação cega

Real / prevista	Ansiedade	Neutro	Tristeza
Ansiedade/hesitação	35	5	0
Neutro	9	31	0
Tristeza	0	0	40

11.3 Escopo da verificação

O resultado de uma suíte de software não mede segurança clínica. A acurácia do classificador usa classes sintéticas, e os alertas estruturados seguem limiares demonstrativos. A integração só pode receber uma métrica multimodal de generalização se houver conjunto pareado, independente e rotulado, inexistente no material disponível.

12 Resultados de vídeo e análise dos casos

12.1 Resultados históricos da frente de vídeo

As métricas abaixo são atribuídas ao relatório da frente de vídeo. Sua preservação documenta o trabalho da equipe; não significa novo treinamento do detector nesta consolidação.

Classe	mAP50	mAP50–95
Geral	0,928	0,636
Instrumentos	0,906	0,538
Útero	0,950	0,734

No teste relatado, a regra com confiança mínima de útero em 0,6 obteve precisão 1,00 e recall 0,72. São medidas do alerta visual na montagem de imagens. Não representam percentual de cirurgias corretamente avaliadas ou detecção de complicações em pacientes.

12.2 Eventos consumidos pela integração

Evento	Início	Fim	Duração	Interpretação técnica
1	76 s	82 s	6 s	Instrumento presente sem área crítica detectada.
2	84 s	114 s	30 s	Persistência da condição; prioridade alta.

Áudio novo03 com modelo regenerado, transcrição real OpenAI do mesmo WAV, análise textual com citações literais, eventos recebidos de vídeo independente e três fontes estruturadas sintéticas. Maior prioridade preservada; relatório e caixa local com confirmação. No caso integrado, a confiança acústica do áudio novo-03 é 0,595, inferior ao limiar 0,70. A fonte de áudio fica inconclusiva e a cobertura permanece incompleta; o alerta alto do vídeo é preservado. Não se declara cobertura completa por terem sido fornecidos todos os arquivos.

12.3 Leitura dos resultados

A decisão final inclui evidência e cobertura. “Sem sinal positivo” não equivale a “paciente sem risco”, sobretudo com fontes ausentes ou em domínio não validado. Os casos sem qualidade suficiente seguem para revisão. Essa distinção evita ocultar uma falha como resultado negativo.

13 Reprodutibilidade, execução e organização

13.1 Preparação

O repositório reúne os notebooks originais, o pacote de integração, scripts, testes e evidências. O dataset utiliza Git LFS; sem baixar seu conteúdo, o arquivo ZIP é apenas um ponteiro. Modelo, características e CSV regenerados devem ser preservados junto do manifesto e da versão do ambiente.

1. Preparar Python e instalar as dependências descritas no README.
2. Executar `python -m pytest -q` para a suíte de software.
3. Executar `python scripts/run_demo.py -help` para conferir entradas e diretório de saída.
4. Informar o CSV regenerado, o JSON de vídeo e o resultado textual real ao script de demonstração.
5. Abrir o painel com `python -m techchallenge4.dashboard -help` e selecionar o banco gerado.
6. Compilar o relatório com `python relatorio/gerar_relatorio.py -compile -package` ou importar o ZIP no Overleaf.

13.2 Modo econômico

Os testes de software e a reprodução de resultados existentes podem ser executados sem GPU. A extração acústica e a transcrição são mais custosas. A nuvem é acionada apenas em chamadas limitadas e com cache. O processamento local de transcrição não consome saldo da API da OpenAI.

13.3 Conservação de artefatos

As evidências públicas incluem contagens, métricas, manifestos, resultados e auditorias sem credenciais. Áudios, vídeos, pesos e bancos de execução ficam em armazenamento apropriado ou em diretório privado ignorado pelo Git. O relatório é disponibilizado em PDF e LaTeX, com ZIP pronto para importação no Overleaf.

13.4 Recursos de execução

GPU local NVIDIA RTX2060. Processamento principal encerrado; nenhuma sessão Colab foi iniciada. GPU utilizada nesta consolidação: sim. Sessão de computação encerrada ao final: sim.

14 Matriz de atendimento ao desafio

A matriz considera os itens das páginas 2–4 do enunciado e o esclarecimento sobre serviços alternativos. O termo “demonstrado” refere-se ao protótipo e ao tipo de dado informado, sem equivalência automática a validação assistencial.

Requisito	**Evidência da solução**	**Limite de interpretação**
Vídeo clínico e evento fora do padrão	YOLOv8 da equipe; JSON e relatório com dois eventos temporais.	Vídeo de avaliação montado; métricas históricas.
Relatório automático	Saídas por vídeo e relatório multimodal por caso.	Evidência de software; exige revisão humana.
Processamento de voz	Whisper, Librosa e Random Forest, com artefatos regenerados.	Dados sintéticos; sem validação de disartria ou fadiga.
Transcrição e análise textual	Whisper para ritmo acústico; transcrição e análise textual OpenAI; fornecedor alternativo autorizado.	Diferenciar síntese, transcrição e análise semântica.
Termos e sentimentos	Resposta estruturada com sentimento, menções, contexto, evidência literal e negação.	LLM pode interpretar incorretamente; não é diagnóstico.
Sinais vitais	Detector de desvio robusto em histórico temporal.	Demonstração sintética e limiar estatístico.
Prescrições	Comparação temporal de dose, unidade, via e intervalo.	Não avalia adequação terapêutica.
Movimentação	Detector de série numérica de movimento.	Não implementa análise postural clínica.
Fusão multimodal	Contrato por caso; prioridade e cobertura explícitas.	Fontes independentes, sem coorte pareada.
Alertas à equipe	Caixa SQLite, painel local e confirmação de revisão.	Entrega local, sem sistema hospitalar real.
Processamento temporal	Monitor JSONL incremental e reprodução; latência dos detectores, fusão e entrega local.	Não comprova captura clínica contínua.
Código completo	Branch Nirton com scripts, notebooks e testes.	Requer dependências e artefatos descritos.
Relatório técnico	PDF, fontes LaTeX e pacote Overleaf.	Resultados restringem-se à evidência registrada.
Vídeo até 15 minutos	Roteiro e material de demonstração preparados.	Gravação e publicação: responsabilidade de Benicio.

15 Limitações, riscos de validade e evolução

15.1 Validade dos dados

Os áudios sintéticos de uma única voz não representam diversidade de pessoas, sotaques, microfones ou estados de saúde. A divisão por frase-base reduz semelhança textual entre partições, mas não cria independência de locutor. O classificador mede o experimento de prosódia utilizado.

No vídeo, a origem detalhada dos clipes e a proximidade de quadros limitam a auditoria de independência. O vídeo montado altera o significado temporal em relação a uma cirurgia contínua. Esses fatores podem produzir estimativas mais favoráveis do que as de dados externos.

15.2 Validade das decisões

Sentimento textual e classe acústica não são indicadores clínicos intercambiáveis. Uma frase negativa pode descrever um evento sem relação com risco; uma negação mal interpretada pode inverter seu significado. O protótipo preserva evidências e exige revisão, mas não elimina esses erros.

Os detectores estruturados usam estatística e regras ilustrativas. Variações de dose podem ser intencionais, e alterações de sinais vitais exigem contexto, unidade e protocolo assistencial. Nenhuma regra deste projeto deve alterar cuidados automaticamente.

15.3 Validade da integração

As fontes disponíveis não são pareadas por paciente e instante. A demonstração comprova compatibilidade de contratos, resposta a cenários e entrega local. Não mede ganho clínico da combinação multimodal. A latência da persistência também não representa o tempo total desde uma ocorrência física até sua avaliação.

15.4 Próximos passos para uso real

Seriam necessários dados externos com autorização e proveniência, protocolo de anotação, especialistas para definir desfechos, validação por paciente e por instituição, calibração, avaliação de falsos negativos e de fadiga de alertas, governança de acesso e integração auditável ao ambiente assistencial. Essas etapas extrapolam o experimento acadêmico entregue.

16 Conclusões e material para demonstração

A consolidação organiza as frentes de áudio e vídeo em uma arquitetura reproduzível, acrescenta análise textual gerenciada e demonstra como um sinal se transforma em alerta persistido e revisado. O trabalho documenta as diferenças entre executar software, reproduzir métricas e validar um sistema para uso clínico.

O protocolo com famílias reservadas é necessário porque o modelo anterior foi ajustado em todo o dataset. A nova avaliação mantém conjuntos separados e identifica claramente o domínio sintético. As métricas de vídeo preservadas são atribuídas à frente responsável e não são reinterpretadas como desempenho em pacientes.

16.1 Sequência recomendada para a apresentação

1. Apresentar o problema, o recorte e as fontes disponíveis.
2. Mostrar um WAV, sua transcrição, características e classe/confiança.
3. Mostrar a origem e os dois eventos do resultado de vídeo.
4. Mostrar a chamada textual real e o registro de consumo, sem credenciais.
5. Executar a composição do caso e explicar como uma fonte neutra não cancela alerta alto.
6. Exibir as séries e prescrições sintéticas e os desvios identificados.
7. Abrir o painel, conferir o alerta e confirmar sua revisão.
8. Exibir os resultados de testes, partições e limitações.

16.2 Entrega audiovisual

A gravação e a publicação do vídeo não integram esta execução técnica. O roteiro atualizado acompanha o repositório. Antes da publicação, o responsável deve selecionar as imagens compatíveis com a orientação da equipe sobre o material de terceiros e preservar a ausência de chaves, dados pessoais e credenciais na tela.

Referências

[1] FIAP. *IADT - Fase 4 - Tech challenge*. Material da disciplina, páginas 2–4, 2026.

[2] FIAP. *Aula 04: transcrição e processamento de áudio*; *Aula 05: classificação e avaliação*; *Integração e automação com a API da OpenAI*. Materiais da Fase 4, 2026.

[3] Equipe Tech Challenge. *Frente de áudio - monitoramento de sinais emocionais pela voz*. https://github.com/Val-Faria/TechChallengeFase4/blob/main/audio/relatorio/secao_audio.md. Consulta: 9 nov. 2026.

[4] Equipe Tech Challenge. *Frente de vídeo - análise de cirurgias ginecológicas*. https://github.com/Val-Faria/TechChallengeFase4/blob/main/relatorio/secao_video.md. Consulta: 9 nov. 2026.

[5] Machinelearning. *Uterus Dataset*, versão 4. Roboflow Universe, 2024. https://universe.roboflow.com/machinelearning-yekk6/uterus-qn1he/dataset/4.

[6] OpenAI. *Structured model outputs*. https://developers.openai.com/api/docs/guides/structured-outputs. Consulta: 9 nov. 2026.

[7] OpenAI. *API pricing*. https://developers.openai.com/api/docs/pricing. Consulta: 9 nov. 2026.

[8] OpenAI. *Whisper*. Código e documentação do modelo de reconhecimento de fala. https://github.com/openai/whisper.

[9] Librosa. *Documentation: feature extraction and pYIN*. https://librosa.org/doc/latest/.

[10] Scikit-learn. *RandomForestClassifier; GroupShuffleSplit; model persistence*. https://scikit-learn.org/stable/.

[11] Ultralytics. *YOLOv8 documentation*. https://docs.ultralytics.com/models/yolov8/.

A Manifesto de evidências e critérios de auditoria

Artefato	SHA-256 (prefixo)
evidence/audio_reproducao.json	eec78c6135392737
audio/evidencias/particoes_audio.csv	30dc41d77d9167b3
audio/evidencias/predicoes_avaliacao.csv	a6b46c44b1312d97
artifacts/audio/manifesto_audio.json	fafd4dbbe961e037
evidence/resumo_execucao.json	b16ac9a8cd7aebef
evidence/audio_externo_transcricoes.json	8da6101b626df962
evidence/asr_comparacao.json	c86c4ff64c6c6263
evidence/audio_externo.json	20d055c33a303003
evidence/audio_recebido_drive.json	99a156e55c61acef
evidence/openai_validacao.json	9e43f13d89c3dc42
evidence/video_validacao.json	17832e5417cf354e
evidence/dashboard_validacao.json	e994518026d1aa81
integracao/evidencias/monitoramento_final/monitoramento_resumo.json	20c95ef1eec67a2b
integracao/evidencias/execucao_final/replay.json	a3b293016c112c8b
integracao/evidencias/execucao_final/entrega_auditoria.json	a868b41a09e7d744
integracao/evidencias/execucao_final/anomalias_estruturadas.json	e5e6f55892ed79b8

Os hashes completos devem ser consultados nos manifestos de execução e no histórico do repositório. O prefixo serve como referência de leitura, não como substituto de uma verificação integral.

A.1 Critérios para revisão

- A contagem declarada deve corresponder ao ZIP e ao CSV regenerados.
- Os hashes dos arquivos de partição devem demonstrar ausência de sobreposição.
- A verificação cega não pode ser incorporada ao treinamento do modelo entregue como avaliado.
- A análise textual deve ter uso retornado pela API e resultado salvo, sem chave ou cabeçalho de autenticação.
- A repetição de uma entrega deve preservar a identidade do alerta e a confirmação de revisão.
- As métricas devem indicar sua origem: reproduzida, histórica ou controlada.
- Nenhuma imagem privada é necessária para compilar este relatório.

B Auditoria final de conformidade com o enunciado

Parecer: o atendimento integral ainda não está demonstrado. A gravação não é a única pendência. O código de nuvem, as séries sintéticas, a fusão e os alertas foram executados; as frentes de vídeo e de alterações vocais médicas mantêm cobertura parcial.

B.1 Pendências funcionais

1. **Vídeo:** disponibilizar o peso personalizado e reproduzir a inferência no vídeo escolhido. A avaliação em mídia inédita foi solicitada adicionalmente pelo integrante; não é um protocolo de divisão imposto no PDF.
2. **Voz:** demonstrar alterações relacionadas às condições do enunciado com cenários, referência e avaliação apropriados. Classificar emoções sintéticas ou reconhecer uma frase que menciona falta de ar não comprova detectar esse sinal na voz.
3. **Tempo real:** o monitor calcula desvios na chegada de séries JSONL. A composição de áudio e vídeo usa resultados calculados anteriormente. Declarar todo o fluxo multimodal contínuo exige executar e medir essa aquisição e inferência.

Não se inferem obrigações adicionais de ensaio hospitalar, homologação médica ou envio de alertas por e-mail. O painel local demonstra encaminhamento e revisão; as limitações de dados sintéticos permanecem explícitas.

B.2 Correções de software verificadas

- Escolha explícita do áudio quando um CSV contém vários arquivos.
- Medidas com referência constante não apagam desvios nas demais; a cobertura parcial é preservada.
- Pressão sistólica e diastólica acrescentadas às duas demonstrações.
- Fontes sem atualização expiram em prazo operacional configurável, sem serem tratadas como observações normais.
- Histórico sintético mantém a proveniência nas decisões posteriores.
- Revisões concorrentes produzem uma única confirmação; exportações usam temporários exclusivos.
- Cache textual confere texto e modelo e recalcula a decisão das menções validadas.
- Integridade de WAVs e modelo conferida; modo de auditoria não sobrescreve partições. Exportações preservam os bytes no Git para manter seus hashes entre sistemas.

A revisão inventariou 28 arquivos Python e três notebooks. A análise sintática e as verificações de erros estáticos passaram. A suíte consolidada tem **59 testes e 26 subtestes aprovados**. Não houve chamadas pagas nem novo treinamento nesta auditoria. O parecer e o plano de fechamento estão em `relatorio/auditoria_conformidade.md`; o inventário está em `evidence/auditoria_projeto.json`.